

Math4CS 全量小抄(公式 + 讲解)

覆盖：顾小东老师（概率·信息论·随机过程·优化）+ 应凯老师（数值算法 NA1~NA8）全部考点，已对齐 12 份复习讲义。
体例：每道题都带一句「讲解」，说明它做什么 / 何时用；👉=高频考点，👈=易错点，💡=口诀/技巧。不含例题完整数值解（见 作业

全解-HW1~6）。
结构：A 数学核心 (§1-4) | B 数值算法 (§5-13)。
一条主线（贯穿全程）：条件数 = 误差放大倍数 = 问题固有属性（与算法无关），且 前向误差 ≈ 条件数 × 后向误差。它在标量求根 (§5, A 数学核心

$\kappa \approx 1/|f'|$)、线性系统 (§9, $\kappa = \sigma_{\max}/\sigma_{\min}$) 里反复出现。矩阵分解地图：一般方阵→LU (§6)；对称正定→Cholesky (§8)；解最小二乘三条路 正规方程→QR (§10)→SVD (§12)，稳定性递增。

1. 概率论

条件概率： $P(X|Y) = \frac{P(X,Y)}{P(Y)}$ 。

讲解：在已知 Y 发生的「子世界」里 X 的概率，等于联合除以条件的边际。

边际化（求和消元）： $P(X) = \sum_y P(X,y)$ 。

讲解：把不关心的变量「加掉」，从联合分布得到边际分布。

全概率公式： $P(E) = \sum_i P(E|H_i)P(H_i)$ ， $\{H_i\}$ 互斥且完备。

讲解：把证据 E 拆到一组完备假设上求和，是贝叶斯分母的算法。👈别只取一项、别漏加。

贝叶斯公式👉： $P(H|E) = \frac{P(H)P(E|H)}{P(E)} = \frac{P(E|H)P(H)}{\sum_i P(E|H_i)P(H_i)}$ 。

讲解：用新证据 E 把先验更新成后验。先验 $P(H)$ =看证据前的信念；后验 $P(H|E)$ =看证据后；似然 $P(E|H)$ =假设成立时证据出现的概率（记作 $L(H|E) = P(E|H)$ ）；证据/边缘似然 $P(E)$ =归一化分母。一句话：贝叶斯 = 先验信念 + (似然) 证据 → 更新成后验。
👈别把 $P(H|E)$ (要求的后验) 与 $P(E|H)$ (已知的似然) 方向记反。

链式法则： $P(X_1, \dots, X_n) = P(X_1)P(X_2|X_1) \cdots P(X_n|X_1, \dots, X_{n-1})$ 。

讲解：任何联合分布都能按顺序拆成一串条件概率之积。

独立 / 条件独立： $A \perp B \iff P(A,B) = P(A)P(B) \iff P(A|B) = P(A)$ ； $X \perp Y|Z \iff P(X,Y|Z) = P(X|Z)P(Y|Z)$ 。

讲解：独立=互不提供信息；条件独立=在已知 Z 后互不提供信息（贝叶斯网络核心）。👈严格独立须对所有取值组合成立。

频率学派 vs 贝叶斯学派：频率派把概率当「长期相对频率」（客观、固定）；贝叶斯派把概率当「逻辑自治的信念度」（主观、随证据更新），适用于不可重复实验。

1.1 贝叶斯网络（紧凑表示联合分布）

动机： n 个二值变量的联合分布表有 $2^n - 1$ 个独立项，指数爆炸。贝叶斯网络用条件独立把它压缩。

结构：有向无环图 (DAG) $G = (V, E)$ 。节点=随机变量；边 $X \rightarrow Y$ 表示父 X 对子 Y 有直接概率影响（“ X 是 Y 的直接原因”）；无边=（条件）独立。

CPT（条件概率表）：每个节点存 $P(X_i | \text{Parents}(X_i))$ ；根节点（无父）存先验 $P(X_i)$ 。

联合分解👉： $P(X_1, \dots, X_n) = \prod_i P(X_i | \text{Parents}(X_i))$ 。

讲解（口诀）：父节点写在条件里、根节点是先验，全部连乘。 n 个节点对应 n 个因子。

推断：求某个后验时，对无关变量边际化（求和消元）后再代入分解。例： $P(R|W) = \frac{P(R,W)}{P(W)}$ ，其中 $P(W,R) = \sum_s \sum_c P(C=c)P(S=s|c)P(R|c)P(W|s,R)$ 。

马尔可夫毯 $MB(X)$ 👉： X 的父节点 + 子节点 + 子节点的其它父节点 (co-parents)。

讲解：给定马尔可夫毯， X 与网络中其余所有节点条件独立——它是「屏蔽 X 所需的最小集合」。👈别漏 co-parents（子的其它父）；叶节点没子，故只有父。

1.2 d-d 分离（判断条件独立的三结构法）👉

判断「给定集合 Z ，节点 X,Y 是否条件独立」：看它们之间所有路径是否都被「阻断」。全断 → 条件独立。

结构	形态	阻断规则
链 Chain	$A \rightarrow B \rightarrow C$	B 被观测 → 阻断
分叉 Fork（共因）	$A \leftarrow B \rightarrow C$	B 被观测 → 阻断
汇聚 Collider（ V -结构）	$A \rightarrow B \leftarrow C$	B (及其后代) 未被观测 → 阻断；观测 B 反而打开

💡 口诀：链和分叉「观测中间点就断」；汇聚「观测汇聚点反而通」。
👈 汇聚反直觉（explaining away，解释消除）： V -结构在 B 未观测时 $A \perp C$ ；观测 B 反而让 A,C 相关。直觉：“结果出现了，知道一个原因没发生，另一个原因就更可能。”

2. 信息论

自信息（信息量）： $I(x) = -\log_2 p(x) = \log_2 \frac{1}{p(x)}$ (bit)。

讲解：单个事件的「惊讶度」——越稀奇信息越多； $p = 1 \Rightarrow I = 0$ 。用 $\log$ 是因为有加：两独立事件 $-\log(p_1 p_2) = -\log p_1 - \log p_2$ 。

信息熵👉： $H(X) = \mathbb{E}[-\log_2 p(X)] = -\sum_x p(x) \log_2 p(x)$ (bit)。

讲解：随机变量的平均不确定性 = 信息量期望 = 最优编码的平均比特数（下界）。均匀分布时最大 (M 个等概率 $\Rightarrow H = \log_2 M$)；某取值得概率为 1 时 $H = 0$ 。 N 个独立、各 M 态事件的信息量 = $N \log_2 M$ bit。

二元熵： $H(p) = -p \log_2 p - (1-p) \log_2 (1-p)$ ，在 $p = 0.5$ 取最大值 1 bit。

联合熵： $H(X,Y) = -\sum_{x,y} p(x,y) \log_2 p(x,y)$ 。

讲解：一对变量的总不确定性。

条件熵： $H(Y|X) = -\sum_{x,y} p(x,y) \log_2 p(y|x)$ 。

讲解：已知 X 后 Y 剩余的不确定性。 X 完全决定 Y 则为 0； X 对 Y 毫无信息则 $H(Y|X) = H(Y)$ 。

链式法则👉： $H(X,Y) = H(X) + H(Y|X) = H(Y) + H(X|Y)$ ；一般 $H(X_{1:n}) = \sum_i H(X_i | X_{1:i-1})$ 。

讲解：总不确定性 = 第一个变量的 + 给定它之后剩下的。考试算条件熵最快： $H(Y|X) = H(X,Y) - H(X)$ ，不必重新求和。👈减的是

5. 误差分析👉

量	公式	能否算
绝对误差	$ x_{\text{est}} - x^* $	需真值，一般算不出
相对误差	$\frac{ x_{\text{est}} - x^* }{ x^* }$	同上
前向误差	$ x_{\text{est}} - x^* $ (解空间)	通常算不出 (需真根)
后向误差=残差	$ f(x_{\text{est}}) $ (方程空间)	能算 (代回 f)
条件数	前向 $\frac{1}{ f'(x^*) }$ 后向 $\frac{1}{ f''(x^*) }$	误差放大倍数

关系式👉：前向误差 ≈ (条件数) × 后向误差。

讲解：前向看「解」 $|x_{\text{est}} - x^*|$ ，后向看「代回方程」 $|f(x_{\text{est}})|$ ，中间隔

「被条件的 X 的熵，别减成 $H(Y)$ 」。

交叉熵： $\text{CE}(p,q) = -\sum_x p(x) \log_2 q(x)$ 。

讲解：真实分布是 p 、却用为 q 设计的编码，平均所需比特数。机器学习里常作分类损失。

KL 散度 / 相对熵： $D_{KL}(p||q) = \sum_x p(x) \log_2 \frac{p(x)}{q(x)} \geq 0$ 。

讲解： p 的编码相比真实 p 多花的「额外比特」，衡量两分布差距。 $D_{KL} = 0 \iff p = q$ (吉布斯不等式)； $D_{KL}(p||q) = \text{CE}(p,q) - H(p)$ 。👈不对称 $D(p||q) \neq D(q||p)$ ，严格说不距离。

互信息👉： $I(X;Y) = \sum_{x,y} p(x,y) \log_2 \frac{p(x,y)}{p(x)p(y)} = D_{KL}(p(x,y)||p(x)p(y))$ 。

讲解：知道 Y 能减少多少 X 的不确定性。三等价式：
 $I(X;Y) = H(X) + H(Y) - H(X,Y) = H(X) - H(X|Y) = H(Y) - H(Y|X)$

对称 $I(X;Y) = I(Y;X)$ ； ≥ 0 ； X,Y 独立 $\Rightarrow I = 0$ 。👈算出负值一定错。Venn 图：两圆 $H(X), H(Y)$ ，交集 = I ，并集 = $H(X,Y)$ ，左右月牙 = $H(X|Y), H(Y|X)$ 。

2.1 决策树

节点：根节点（全数据）、内部节点（对某属性测试）、分支（测试结果）、叶节点（类标签）。

构造原则：选属性使分裂后类别 Y 的条件熵最小。

属性选择：选信息增益最大者

$IG(Y,X) = H(Y) - H(Y|X) = I(Y;X)$ 。

讲解：信息增益 = 用属性 X 划分后不确定性下降量，恒等于互信息。👈属性取值恒定 $\Rightarrow IG=0$ （切不开数据）。

2.2 概念判断速记（高频判断题）

- 「熵越大 $\rightarrow$ 对事情越确信」→ 错（熵大=越不确定/越难猜）。
- 「交叉熵 / KL 衡量两分布的差异/距离」→ 对（但记住 KL 不对称、非真距离）。
- 决策树选特征 $\rightarrow$ 选信息增益 $I(Y;A)$ 最大者；无区分力特征 $IG=0$ 。

👉 常用对数值： $\log_2 \frac{1}{2} = -1, \log_2 \frac{1}{4} = -2, \log_2 \frac{1}{8} = -3; \log_2 3 \approx 1.585, \log_2 5 \approx 2.322, \log_2 6 \approx 2.585; \log_2 256 = 8$ 。约定 $0 \log 0 = 0$ 。

3. 随机过程与马尔可夫

马尔可夫性质： $\mathbb{P}[S_{t+1} | S_1, \dots, S_t] = \mathbb{P}[S_{t+1} | S_t]$ 。

讲解：「给定现在，未来与过去无关」——无记忆性。本质是时间上的条件独立（与 §1 条件独立同源）。

转移矩阵： $p_{ij} = P[S_{t+1} = j | S_t = i]$ ，每行和为 1 ($\sum_j p_{ij} = 1$)。

讲解：行=当前状态，列=目标状态；是个随机矩阵。👈行和为 1（不是列），检查矩阵先验证这点。

n 步转移（单点 $\rightarrow$ 单点）👉： $P[S_{t+n} = j | S_t = i] = (P^n)_{ij}$ 。

讲解：矩阵幂的 (i,j) 元就是 n 步后从 i 到 j 的概率。

分布演化（整个分布）👉： $\pi_n = \pi_0 P^n$ (π 为行向量，左乘)。

👈最易丢分：问「从 i 出发 n 步到 j 」用 $(P^n)_{ij}$ 个元素；问「整个分布如何演化」用行向量 $\pi_0 P^n$ 。本课约定分布是行向量、右乘 P 。

平稳分布： $\pi = \pi P$ （即 $\pi_{n+1} = \pi_n$ ）且 $\sum_i \pi_i = 1, \pi = \lim_{n \rightarrow \infty} \pi_0 P^n$ 。

讲解：长期稳定、不再随时间变化的分布；是 P 对应特征值 1 的左特征向量（与 §11 特征值问题相通）。👈解 $\pi = \pi P$ 后必须加归一化 $\sum \pi_i = 1$ ，否则解不唯一。对「性质好」（不可约、非周期）的链，从任何初始分布都收敛到同一 π 。

马尔可夫决策过程 MDP：五元组 $(S, A, \{P_{sa}\}, R, \gamma)$ —— 状态集、动作集、转移概率、奖励 $R: S \times A \rightarrow \mathbb{R}$ 、折扣 $\gamma \in [0,1)$ 。

讲解：带「决策 + 奖励」的马尔可夫过程，目标最大化长期回报。折扣回报 $R_t = \sum_{i=t}^\infty \gamma^i r_i = r_t + \gamma v_{t+1} + \dots$ ， γ 让近期奖励比远期值钱、并保证无穷和收敛； γ 越小越短视。Bellman 一步备份 $Q(s,a) = R(s,a) + \gamma \sum_{s'} P(s' | s,a) V(s')$ 。

4. 优化

一般形式： $\min f_0(x)$ s.t. $f_i(x) \leq 0$ ($i=1..m$), $h_j(x) = 0$ ($j=1..p$), $x \in \chi$ 。等价变换： $\max f \iff \min(-f)$ ； $g \geq 0 \iff -g \leq 0$ ； $g = 0 \iff g \geq 0$ 且 $-g \leq 0$ 。

讲解：所有问题都能化成「min + 不等式 ≤ 0 + 等式 = 0」的标准模板。 $-\nabla f_0$ = 下降最快方向；最优 x^* 常在「目标等高线与可行域边界相切」处。

4.1 凸性与正定 (PSD/PD)

凸函数： $f(\theta x + (1-\theta)y) \leq \theta f(x) + (1-\theta)f(y)$, $0 \leq \theta \leq 1$ （割线在曲线上方）。

讲解：凸优化的核心好处——任何局部最优都是全局最优（“碗”👉，无杂数坑），通常有多项式算法。

正定 / 半正定： $\forall x, x^\top A x \geq 0 \Rightarrow A \succeq 0$ (PSD)； $\forall x \neq 0, x^\top A x > 0 \Rightarrow A \succ 0$ (PD)。

讲解：等价于「对称 + 所有特征值 ≥ 0 (PD 则 > 0)」。PD $\Rightarrow$ PSD。关键链： $P \succeq 0 \iff f(x) = x^\top P x$ 凸 $\iff$ 图像是碗 $\iff$ QP/QCQP 可漂亮求解。

👉 2x2 对称判 PD (Sylvester)： $P_{11} > 0$ 且 $\det P > 0$ （顺序主子式全正）。

$A^\top A$ 永远 PSD： $x^\top (A^\top A) x = \|Ax\|_2^2 \geq 0 \Rightarrow$ 最小二乘永远凸。
几何对照：diag(1,1) 朝上的碗 (PD)；diag(1,0) 水槽 (PSD)；diag(1,-1) 马鞍 (不定)。

4.2 范数与内积（线代复习）

内积 $x^\top y = \sum_i x_i y_i$ (= 0 即正交)。向量 p -范数： $\|x\|_p = (\sum_k |x_k|^p)^{1/p}$ ； $\|x\|_\infty = \max_k |x_k|$ 。（详见 §9。）

B 数值算法

👈看条件数。👈残差小 $\neq$ 解准。

条件数泰勒推导（必考流程）：① 一阶泰勒 $f(x_{\text{est}}) \approx f(x^*) + f'(x^*)(x_{\text{est}} - x^*)$ ；② $f'(x^*) = 0$ 消去首项 $\rightarrow f(x_{\text{est}}) \approx f'(x^*)(x_{\text{est}} - x^*)$ ；

③ 整理 $|x_{\text{est}} - x^*| \approx \frac{|f(x_{\text{est}})|}{|f'(x^*)|} \rightarrow \textcircled{4} \kappa \approx \frac{1}{|f'(x^*)|}$ 。

👉 换阶规则（极易漏）：「求几阶的根，就用高一阶的导数」。求根 $f \rightarrow 0 \rightarrow \kappa \approx 1/|f'|$ ；求极小/极大 $f' \rightarrow 0 \rightarrow$ 后向误差 $|f'(x_{\text{est}})|, \kappa \approx 1/|f''(x^*)|$ ；求拐点 $g'' = 0 \rightarrow \kappa \approx 1/|g'''|$ 。

良态 / 病态： $f'(x)$ 大（根处陡） $\rightarrow \kappa$ 小 $\rightarrow$ 良态（残差小则解准）； $f'(x)$ 小（根处平） $\rightarrow \kappa$ 大 $\rightarrow$ 病态（残差小也骗人）。👈条件数是问题固有属性，与算法无关——病态问题再好的算法也救不了。

4.3 凸优化问题分类 (LP $\subset$ QP $\subset$ QCQP; GP 另一支)👉

类型	目标	约束	形式
LP 线性规划	线性	线性	$\min c^\top x$ s.t. $Ax \leq b, x \geq 0$
QP 二次规划	凸二次	线性	$\min \frac{1}{2} x^\top P x + q^\top x + r$ s.t. $Ax \leq b$, 需 $P \succeq 0$
QCQP 二次约束二次规划	凸二次	二次	$\min \frac{1}{2} x^\top P_0 x + q_0^\top x + r_0$ s.t. $\frac{1}{2} x^\top P_i x + q_i^\top x + r_i \leq 0, Ax = b$, 所有 $P_i \succeq 0$
GP 几何规划	posynomial	posynomial $\leq$, monomial=	$\min f_0$ s.t. posynomial $\leq b_i$, monomial = $b_j, x > 0$
SDP 半定规划	线性	半正定矩阵约束	谱系语言 LP $\subset$ QP $\subset$ SOC $\subset$ SDP $\subset$ Convex

👉 判别口诀（从最严的类倒着排除）：全线性=LP；目标二次+约束线性=QP；只要有一条二次约束=QCQP；负指数/变量相除/ $x > 0$ =GP。

👈陷阱：① 目标线性但有二次约束 $\rightarrow$ QCQP 不是 LP（如 $\min 2x_1 + x_2$ s.t. $x_1^2 + x_2^2 \leq 5$ ）；② $x_i^2 = 1 / x_i \in \{-1,1\}$ 是非凸（离散点集，NP-hard，如 Max Cut），看似 QCQP 实则不可凸解；③ QP 必须 $P \succeq 0$ 否则非凸。

单项式 / 正项式：单项式 $f(x) = c x_1^{a_1} \cdots x_n^{a_n}$ ($c \geq 0, a_i \in \mathbb{R}$ 任意实数，可负可分数)；正项式 (posynomial) = 单项式之和。

讲解：GP 通过 $x = \log x$ 代换，单项式 $\rightarrow e^{a^\top x + \log c}$ ，posynomial 变 $\log\text{-sum-exp}$ (凸)，整个 GP 转成凸问题用内点法解。👈GP 单项式指数可任意实数（和高中“单项式”不同），系数须 $\geq 0, x > 0$ 。

4.4 LP 标准形 + 四条转换规则

标准形 $\max c^\top x$ s.t. $Ax \leq b, x \geq 0$ 。几何：每条 $a_i^\top x \leq b_i$ = 半空间，交集 = 多面体；👉最优解（若存在且有界）必在多面体某角点（顶点）——单纯形法在角点间跳。

- $\min c^\top x \iff \max(-c)^\top x$ ；
- $a^\top x \geq b \rightarrow -a^\top x \leq -b$ ；
- $a^\top x = b \rightarrow a^\top x \leq b$ 且 $-a^\top x \leq -b$ ；
- 自由变量 $x_j = x_j^+ - x_j^-$ ($x_j^\pm \geq 0$)。
- 绝对值线性化： $|x| = \min\{t : x \leq t, -x \leq t\}$ ，最小时 t 被压到 = $|x|$ ；目标里的 $|x|$ 换成 t 。

4.5 无约束极小化

- 最优条件 (f 凸、二阶连续可导)： $\nabla f(x^*) = 0$ 。梯度 $\nabla f = (\frac{\partial f}{\partial x_1}, \dots, \frac{\partial f}{\partial x_n})^\top$ 。
- 梯度下降： $x^{(t+1)} = x^{(t)} - \eta_t \nabla f(x^{(t)})$ 。
- 讲解：沿负梯度（最速下降）走， η_t 步长。一阶方法，便宜但慢。最大化改 $+\eta \nabla f$ (梯度上升)。
👈步长效应：太小 $\rightarrow$ 慢；太大 $\rightarrow$ 在最低点两侧振荡；非常大 $\rightarrow$ 发散。曲率悬殊（如 $0.01x_1^2 + x_2^2$ ） $\rightarrow$ Z-字形极慢，出路是归一化或用牛顿法。带约束时一步步后投影回可行域。
👈牛顿法： $x^{(t+1)} = x^{(t)} - [\nabla^2 f(x^{(t)})]^{-1} \nabla f(x^{(t)})$, Hessian $\nabla^2 f = (\frac{\partial^2 f}{\partial x_i \partial x_j})$ 。
- 讲解：用二阶泰勒近似，收敛快。👉对任何凸二次 $f = \frac{1}{2} x^\top P x + q^\top x + r$ ($P \succ 0$)，从任意点一步到 $x^* = -P^{-1}q$ 。代价：Hessian $O(n^2)$ 存、 $O(n^3)$ 求逆，大规模用 L-BFGS/Adam。
- 下降方向判据： d 是 x 处下降方向 $\iff \nabla f(x)^\top d < 0$ （与负梯度夹角 $< 90^\circ$ ）。

4.6 有约束极小化：罚函数 / 内点法

拉格朗日乘子法： $L(x, \lambda) = f(x) + \sum_i \lambda_i g_i(x)$ ，把约束并进目标。二次罚（外点罚）：等式约束 $h(x) = 0 \rightarrow \min f_0(x) + \frac{\rho}{2} h(x)^2$ 。

讲解：满足约束罚=0，违反给平方惩罚， ρ 由小到大。用平方（非 $| \cdot |$ ）因处处可行。👉适用区分：允许迭代点暂时不可行 $\rightarrow$ 二次罚；要求始终严格可行 $\rightarrow$ 内点/障碍法。

内点法 / 对数障碍（可微近似指示罚）：理想指示 $I_-(u) = 0$ ($u \leq 0$) 或 ∞ ($u > 0$) (不可微)，近似 $I_-(u) \approx -\log(-u)$ 。

$\min f_0(x) + \mu \varphi(x), \quad \varphi(x) = -\sum_i \log(-g_i(x))$ s.t. $Ax = b$

讲解： $u \rightarrow 0^-$ （逼近边界）惩罚 $\rightarrow \infty$ ，像「无形的墙」把点关在内部（故名 interior）。中心路径 $(x^*(\mu))$ ： μ 大 $\rightarrow$ 解被推到可行域中心（好解）； $\mu \rightarrow 0^+$ $\rightarrow$ 逼近真最优（常在边界角，越来越病态）。

障碍法（路径跟踪）：给定可行 x 、容差 ϵ 、缩减因子 $0 < \beta < 1$ ，重复：① 中心步（牛顿法解 $\min \mu f_0 + \varphi$ ）② 更新 x ③ 若 $m\mu < \epsilon$ 停 ④ $\mu \leftarrow \beta \mu$ 。对比：单纯形走外边角点，内点法走内里中心路径。

4.7 对偶与 KKT（真题 Q5 考点）👉

Lagrange 对偶构造（对 $\min f_0$ s.t. $f_i(x) \leq 0$ 乘子 $\mu_i \geq 0, h_j(x) = 0$ 乘子 ν_j 无限制）

- Lagrange 函数 $L(x, \mu, \nu) = f_0(x) + \sum_i \mu_i f_i(x) + \sum_j \nu_j h_j(x)$ ；
- 对偶函数 $g(\mu, \nu) = \inf_x L$ （凸时令 $\nabla_x L = 0$ 解出 x 代回）；
- 对偶问题 $\max_{\mu \geq 0, \nu} g(\mu, \nu)$ ，最优值 d^* 。

讲解： g 是把约束「折价塞进目标」后取下确界得到的下界函数；对偶就是把下界顶到最高。

弱对偶 $d^* \leq p^*$ （恒成立）；强对偶 $d^* = p^*$ 当凸 + Slater 条件（存在严格可行内点；仿射约束更宽松）。

KKT 条件（约束 $g(x) \leq 0, L = f_0 + \mu g$ ）四条：

$\nabla f_0 + \mu \nabla g = 0, \quad g(x) \leq 0, \quad \mu \geq 0, \quad \mu g(x) = 0$

👉 求解第一步——判约束是否 active：先求无约束最优 $\hat{x}$ ；若 $\hat{x}$ 满足约束 $\rightarrow$ 约束失效， $\mu^* = 0, x^* = \hat{x}$ ；若越界 $\rightarrow$ 约束 active ($g = 0$)， $\mu^* > 0$ ，联立平稳性 + $g(x) = 0$ 解。凸问题满足 KKT $\iff$ 全局最优。

形状	名称	解
$m = n$ 方阵满秩	适定	唯一解
$m > n$ 高维	超定 over-determined	一般无解→最小二乘 (§7)
$\$m$	欠定 under-determined	无穷多解→最小范数解 (§7)

细则：唯一解需 A 方阵可逆，或 $m > n$ 列满秩且 $b \in \text{Col}(A)$ ；无解 $\iff b \notin \text{Col}(A)$ 。

三种行操作矩阵：

操作	矩阵	逆
置换 (换行)	P (交换 I 的行)	自身
缩放 (行 $\times$ 常数)	$S = \text{diag}(a_i)$	对角元取倒数
消元	$E = I + \mu_{rs}E^{(rs)}$ ，乘子带负号	乘子变号 ("减回去"="加回来")

LU 分解 👉： $A = LU$ ， L 下三角 (对角线全 1、下方存乘子 $m_{ij} = a_{ij}/a_{jj}$)， U 上三角 (消元结果)。

讲解：高斯消元 $E_k \cdots E_1 A = U \Rightarrow A = E_1^{-1} \cdots E_k^{-1} U = LU$ ，这堆逆连乘恰是下三角 L 。前提：消元不需换行时 LU 唯一。

♡ 手算口诀：前向消元用 $U \rightarrow$ 乘子变号写 $L \rightarrow$ 前代解 $y \rightarrow$ 回代解 $x \rightarrow$ 代回验算。

解法：令 $Ux = y$ ，先 $Ly = b$ (前代，从上往下 $y_{i-1}=\text{frac1{\{i\}}}[b_i-\text{sum}_j\{i\text{代},\text{从下往上}x_j=\frac{1}{u_{ii}}[y_i-\text{sum}_{j>i}\{u_{ij}y_j\}]]$)。

复杂度 👉：分解 $O(n^3)$ (约 $n^3/3$)，每个 b 前代+回代各 $O(n^2)$ 。为什么用 LU：同一 A 多个 b 时，只分解一次，后续每个 b 只花 $O(n^2)$

选主元：主元为 0 不能直接消元 (除零) $\rightarrow$ 用置换换得 $PA = LU$ 。▲ 消元中「主元变 0」 $\neq$ 矩阵不可逆 (换行即可)；真正奇异的标志是消元到底后 U 对角线有 0 ($|\prod u_{ii} = \pm \det A = 0$)。

7. 最小二乘与正规化

回归：广义线性模型 $f(x) = c_1\varphi_1(x) + \cdots + c_p\varphi_p(x)$ (对参数 c_j 线性，对 x 可非线性)， m 个数据点构成 $\Phi c = y$ ， $\Phi_{kj} = \varphi_j(x_k)$ 。

讲解：多项式回归取 $\varphi_i(x) = x^{i-1}$ ， Φ 是范德蒙 (Vandermonde) 矩阵。恰定 (n 点 n 参) 时方阵直解；点多于参 $\rightarrow$ 超定 $\rightarrow$ 最小二乘。

最小二乘： $Ax \approx b$ 无精确解 (过定 $m > n$) 时， $\min_x \|b - Ax\|_2 = \sum_i (\text{预测}-\text{观测})^2$ 。

正规方程 (推导三步)：① 展开 $\|Ax - b\|_2^2 = x^\text{T} A^\text{T} Ax - 2b^\text{T} Ax + b^\text{T} b$ (中间项系数 -2 ，因 $x^\text{T} A^\text{T} b = b^\text{T} Ax$ 标量)；② 梯度置零 $2A^\text{T} Ax - 2A^\text{T} b = 0$ ；③ ▮ $A^\text{T} Ax = A^\text{T} b$ ，列满秩则 $x = (A^\text{T} A)^{-1} A^\text{T} b$ 。

讲解：几何——残差 $Ax - b \perp$ 列空间 (Ax 是 b 在列空间的正交投影，即 $A^\text{T} (b - Ax) = 0$ ，"normal=正交"。▲ 缺点：把条件数平方 (见 §9)，病态时改 QR/SVD。

Gram 矩阵 $A^\text{T} A$ ：对称、半正定 ($x^\text{T} A^\text{T} Ax = \|Ax\|_2^2 \geq 0$)；列满秩则正定可逆，可用 Cholesky 解。

直线拟合 $y = kx + b$ 模板： $A^\text{T} A = \begin{bmatrix} \sum x_i^2 & \sum x_i \\ \sum x_i & m \end{bmatrix}$ ， $A^\text{T} y = \begin{bmatrix} \sum x_i y_i \\ \sum y_i \end{bmatrix}$ ， 2×2 求逆即可。验残差 $\perp$ 两列： $\sum r_i = 0$ 且 $\sum x_i r_i = 0$ 。

最小范数解 (欠定 $\$m$

讲解： x_s 落在行空间，其余可行解的「自由分量」在零空间、与 x_s 正交，勾股定理范数最小。**证明套路**：①验可行 $Ax_s = b$ ；②证 $(x - x_s) \perp x_s$ (靠 $A(x - x_s) = 0$)；③勾股 $\|x\|_2^2 = \|x - x_s\|_2^2 + \|x_s\|_2^2 \geq \|x_s\|_2^2$ 。👉 镜像记忆：超定用 $A^\text{T} A$ ，欠定用 AA^T 。

正规化 (加惩罚防过拟合、改善条件)：

Tikhonov / 岭 (L2)： $\min \|Ax - b\|_2^2 + \lambda \|x\|_2^2$ ，解

▮ $(A^\text{T} A + \lambda I)x = A^\text{T} b$ 。

讲解： $\lambda > 0$ 把每个特征值抬高 λ ，使 $A^\text{T} A + \lambda I$ 必正定可逆、条件数变好； λ 大 $\rightarrow$ 解小而平滑 (偏差大)， λ 小 $\rightarrow$ 近原最小二乘。图像去模糊模板 $\min \|Gx - x_0\|_2^2 + \lambda \|x\|_2^2$ 。

Lasso (L1)： $\min \|Ax - b\|_2^2 + \beta \|x\|_1$ —— 产生稀疏解。

Elastic Net：L1+L2 折中。

8. Cholesky 分解 (考概念 + 与 QR 关系)

定义：对称正定 $C \succ 0 \Rightarrow C = LL^\text{T}$ ， L 下三角、对角元为正。

讲解：LU 在 SPD 下的特化版，省一半内存、省一半计算，无需选主元就稳定。解 SPD 系统：前代 $Ly = b +$ 回代 $L^\text{T} x = y$ 。存在条件仅对称正定 (对角元开方时根号内须 > 0)。

递推求 L ： $\$L_{[j]}=\sqrt{\text{c}[c_{[j]}]-\text{sum}_k\{k$

▮ 直觉：对角元开方，非对角元「减掉已算部分再除以对角元」。

SPD 判别 (Sylvester)：所有顺序主子式 $> 0 \iff$ SPD (也可所有特征值 > 0)。

与 QR 的关系 (往年大题，§10.5 译)： $A = QR \Rightarrow A^\text{T} A = R^\text{T} R$ ，对比 Cholesky $A^\text{T} A = LL^\text{T}$ 得 ▮ $L = R^\text{T}$ ，▲ 是 $L = R^\text{T}$ 不是 $L = R$ 。

9. 范数 · 条件数

向量范数 (单位球形状)： $\|x\|_1 = \sum_i |x_i|$ (菱形)、 $\|x\|_2 = \sqrt{\sum x_i^2}$ (圆)、 $\|x\|_\infty = \max_i |x_i|$ (方形)。例 $x = (3, -4)$ ： $\|x\|_1 = 7$ ， $\|x\|_2 = 5$ ， $\|x\|_\infty = 4$ 。

诱导 (算子) 矩阵范数 👉： $\|A\| \equiv \max_{x \neq 0} \frac{\|Ax\|}{\|x\|}$ (矩阵作为变换的最大拉伸率)。

范数	计算	口诀
$\ A\ _1$	$\max_j \sum_i a_{ij} $	最大列绝对和 ("1 看列")
$\ A\ _\infty$	$\max_i \sum_j a_{ij} $	最大行绝对和 ("∞ 看行")
$\ A\ _2$	$\sqrt{\lambda_{\max}(A^\text{T} A)} = \sigma_{\max}$	谱范数 (最大奇异值)

Frobenius 范数 ("展开"，区别于诱导)： $\|A\|_F = \sqrt{\sum_{i,j} a_{ij}^2} = \sqrt{\sum_i \sigma_i^2}$

▲ $\|A\|_F \neq \|A\|_2$ 。

矩阵条件数 👉： $\text{cond}(A) = \|A\| \|A^{-1}\|$ ； $\text{cond}_2(A) = \frac{\sigma_{\max}}{\sigma_{\min}}$ ； A 不可逆则 $= \infty$ 。

讲解：残差 $Ax = b$ 时输入相对误差被放大的最大倍数。解 1 良态，很大病态。正交矩阵 $\text{cond}_2 = 1$ (最理想)。▲ $\text{cond}(A) \geq 1$ 恒成立 ($\|A\| \|A^{-1}\| \geq \|AA^{-1}\| = \|I\| = 1$)，算出 < 1 一定错。

扰动放大不等式：近似解 x 、残差 $r = b - Ax$ ： $\frac{\|\tilde{x} - x\|}{\|x\|} \leq \text{cond}(A) \frac{\|r\|}{\|b\|}$ 。

▮ 讲解：残差再小，解的相对误差也可能被 $\text{cond}(A)$ 放大那么多倍——「病态系统」「残差小」靠不住。

条件数平方定理 👉：▮ $\text{cond}_2(A^\text{T} A) = [\text{cond}_2(A)]^2$ 。

讲解： $A^\text{T} A$ 特征值是 A 奇异值的平方，故条件数平方。这是法方程数值上不如 QR/SVD 的根本原因—— A 病态 (10^4) 则 $A^\text{T} A$ 到 10^8 ，有效数字损失翻倍。

10. QR 分解👉

定义： $A \in \mathbb{R}^{m \times n}$ ($m \geq n$ ，列满秩) $= QR$ ， Q 列正交、 R 上三角 (记录"如何用正交方向组合回原列")。

• 完全 QR： $Q \in \mathbb{R}^{m \times m}$ (真正交方阵)， $R \in \mathbb{R}^{m \times n}$ (下方 $m - n$ 行为 0) —— Householder 产出。

• 约化 QR： $Q \in \mathbb{R}^{m \times n}$ ， $R \in \mathbb{R}^{n \times n}$ —— Gram-Schmidt 产出。 $A = [Q_1 Q_2] \begin{bmatrix} R_1 \\ 0 \end{bmatrix} = Q_1 R_1$ 。

正交矩阵： $Q^\text{T} Q = QQ^\text{T} = I \iff Q^{-1} = Q^\text{T}$ 。

▮ 讲解：保长保内积保角度 $\|Qx\|_2 = \|x\|_2$ 、 $(Qx)^\text{T} (Qy) = x^\text{T} y$ (证： $\|Qx\|_2^2 = x^\text{T} Q^\text{T} Qx = x^\text{T} x$)。几何上是旋转/反射，不拉伸 $\Rightarrow$ 不放大误差、 $\text{cond}_2 = 1$ 、数值稳定。

投影 / 正交分解： $\text{proj}_q(a) = (a^\text{T} q) q$ ($\|q\| = 1$)， $a = \underbrace{(a^\text{T} q) q}_\text{平行} + \underbrace{\quad}_\text{垂直} \perp q$ 。

▮ $(a - (a^\text{T} q) q)$ 。

 垂直 $\perp q$

▮ 讲解：减掉投影后影与 q 正交 —— Gram-Schmidt 的全部秘密。

10.1 Gram-Schmidt

经典 GS (CGS)： $q_1 = a_1 / \|a_1\|$ ； $\$v_j=a_j-\text{sum}_i\{i$

讲解：逐列减掉在已有正交方向上的投影再单位化。▲ R_{ij} 用原列 a_j (不是 v_j)； q_3 要减 q_1, q_2 两个投影；忘归一化则 R 错。

修正 GS (MGS)：唯一区别——算出 q_i 立刻从剩余所有列减去其分量 ($r_{ij} = q_i^\text{T} v$ 用当前已减过的 v)。

讲解：数学结果同 CGS；浮点及时吃掉舍入，正交性损失小得多。

问「为什么用 MGS」答：数值更稳。

10.2 Householder 反射

反射矩阵： $H_v = I - \frac{2vv^\text{T}}{v^\text{T} v}$ ($\|v\| = 1$ 则 $H = I - 2vv^\text{T}$)。性质： $H^\text{T} = H$ (对称)、 $H^2 = I$ (自逆， $H^{-1} = H$)、正交。

讲解：关于「 H 为法向的超平面」的镜面反射，反射两次回原地。▲ 漏系数 2 就不是反射 (不正交)。

清零取法：把列 A 反射成 ce_1 ，取 $v = a - ce_1$ ， $c = \pm \|a\|_2$ 。

讲解：手算用 $c = +\|a\|$ ；数值上取 $c = -\text{sgn}(a_1) \|a\|$ (避免相减相消)。两符号都给合法 QR，只差列正负号。▲ 若某列已是 ce_1 形 (如 $(1, 0, 0)^\text{T}$) 则 $v = 0$ ， $H = I$ 、跳过。

Householder QR：逐列构造 H_{ik} 把对角线下方清零， $H_{n-1} \cdots H_1 A = R$ ，故 $A = \underbrace{H_1 \cdots H_{n-1}}_Q R$ (每个 H 自逆，挪到右边直接连乘)。 Q 常隐式存储 (只存 v_i)。

10.3 用 QR 解最小二乘

代入正规方程 $A = QR$ 、 $Q^\text{T} Q = I$ ： $R^\text{T} Q^\text{T} Q Rx = R^\text{T} Q^\text{T} b \Rightarrow$

▮ $R_{1:n} = Q_1^\text{T} b$ (回代)，最小残差 $^2 = \|Q_2^\text{T} b\|_2^2$ 。

▮ 讲解：全程不碰 $A^\text{T} A$ ，条件数没被平方，比方方程稳； R_1 上三角直回代。

10.4 三种最小二乘解法对比

方法	复杂度	稳定性	备注
法方程+Cholesky	$\sim mn^2 + \frac{1}{3}n^3$	最差 (cond 平方)	最快、 A 良态够用
Gram-Schmidt(MGS)	$\sim 2mn^2$	中	出约化 QR
Householder QR	$\sim 2mn^2 - \frac{2}{3}n^3$	最好 (后向稳定)	工业默认

稳定性总排序：SVD $\gg$ Householder $>$ MGS $>$ CGS $>$ 法方程。

10.5 Cholesky $\leftrightarrow$ QR 关系 (往年大题)

$A = QR \Rightarrow A^\text{T} A = R^\text{T} Q^\text{T} QR = R^\text{T} R$ 。

讲解：对 $A^\text{T} A$ 做 Cholesky 得的 L^T 正是 QR 的 R (差每行正负号)，即 $L = R^\text{T}$ 。反问： $M = A(L^\text{T})^{-1}$ 可验 $M^\text{T} M = I$ (正交)，则 $A = ML^\text{T}$ 是约化 QR， $Q = M, R = L^\text{T}$ 。会背 $A^\text{T} A = R^\text{T} R$ 比死算更重要。

11. 特征值与特征向量

定义： $Au = \lambda v$ ($v \neq 0$) $\Rightarrow (A - \lambda I)v = 0 \Rightarrow \boxed{\det(A - \lambda I) = 0}$ ， λ =特征值， v =特征向量 (方向，常取 $\|v\|_2 = 1$)。

▮ 讲解：特征向量是被 A 只缩放、不转向的方向。

性质速查：

性质	结论
迹	$\text{tr}(A) = \sum_i \lambda_i$
行列式	$\det(A) = \prod_i \lambda_i$
三角矩阵	特征值=对角元 (别展开行列式)
逆 A^{-1}	特征值 $1/\lambda_i$ ，特征向量不变
移位 $A - \sigma I$	特征值 $\lambda_i - \sigma$ ，特征向量不变
秩 $1 uv^\text{T}$	特征值 $\{u^\text{T} v, 0, \dots, 0\}$

谱 / 谱半径：谱=全体特征值集合； $\rho(A) = \max_i |\lambda_i|$ 。

谱定理 (仅实对称 $A = A^\text{T}$) 👉：① 特征值全实；② 不同特征值的特征向量正交；③ 可正交对角化 ▮ $A = Q\Lambda Q^\text{T}$ (Q 正交)。

讲解：对称矩阵=沿一组互相垂直的轴各自拉伸 (SVD 的根基)。复版本 Hermitian $A = A^*$ 同样实对称值。▲ 一般 (非对称) 矩阵特征值可复、特征向量未必正交，别乱套谱定理。

变分视角 / PCA： $\max_x x^\text{T} Ax$ s.t. $\|x\|_2 = 1$ ，拉格朗日 $\Rightarrow Ax = \lambda x$ ，最大值=最大特征值=数据方差最大方向=第一主成分。降维保留大特征值方向 (信息多)，丢小的。

解 $Ay = b$ (对称)： $b = \sum_i c_i a_i$ ($c_i = b^\text{T} x_i$)， $y = \sum_i (c_i/\lambda_i) x_i$ 。

11.1 幂迭代 (Power Iteration, 考纲不考计算、考概念)

$z^{(k)} = Aq^{(k-1)}$ ， $q^{(k)} = z^{(k)} / \|z^{(k)}\|_2$ ， $\lambda^{(k)} = \frac{(q^{(k)})^\text{T} A q^{(k)}}{(q^{(k)})^\text{T} q^{(k)}}$ (瑞利商读特征值)。

▮ 讲解：反复乘 A 并归一化，向量收敛到最大模特征值对应的特征向量。▲ 找的是「绝对值最大」($\lambda = -5$ 比 $\lambda = 3$ 更主导，常见陷阱)，不是代数值最大。为何收敛： q_0 按特征向量展开，每乘一次 A 第 i 分量放大 λ_i 倍，最大的一家独大。

适用条件：① 存在唯一主特征值 $|\lambda_1| > |\lambda_2| > \cdots$ ；② 可对角化方阵；③ 初始向量与主特征向量正交。收敛速度： $\propto |\lambda_2/\lambda_1|$ (次主/主之比)，越小越快。▲ 不收敛情形：两个最大模特征值绝对值相等 (如 $\lambda = \pm 1$) $\rightarrow$ 无唯一主导者，振荡不收敛 (HW5.1)。秩 $1 uv^\text{T}$ 则一步收敛 (Ax 已在 u 方向)。

变体：

- 逆幂法 (求最小特征值)：对 A^{-1} 幂迭代 (特征值 $1/\lambda$)，每步解 $Ax_{k+1} = x_k$ (LU 一次、反复回代，不求逆)。
- 移位逆幂法 (求最接近 σ 的)：对 $A - \sigma I$ 逆迭代。
- 瑞利商迭代：每步用当前瑞利商当移位，三次收敛 (极快)。

12. SVD 分解👉

定义：任意 $A \in \mathbb{R}^{m \times n}$ ，▮ $A = U\Sigma V^\text{T}$ 。

矩阵	大小	性质
U (左奇异向)	$m \times m$	正交 $U^\text{T} U = I$ ，列是 AA^T 特征向量，张成列空间
Σ (奇异值)	$m \times n$ (同 A 形)	矩形对角， $\sigma_1 \geq \cdots \geq \sigma_r > 0 = \cdots$
V (右奇异向)	$n \times n$	正交 $V^\text{T} V = I$ ，列是 $A^\text{T} A$ 特征向量，张成行空间

$\sigma_i = \sqrt{\lambda_i(A^\text{T} A)} = \sqrt{\lambda_i(AA^\text{T})} \geq 0$ ，非零奇异值个数 = $\text{rank}(A) = r$ 。

▲ U 是 $m \times m$ 、 V 是 $n \times n$ ，别搞反。

几何图景：单位球 $\xrightarrow{A}$ 椭球，半轴长= σ_i 、半轴方向= u_i 。从右往左读 $A = U\Sigma V^\text{T}$ ：① V^T 旋转 (输入) $\rightarrow$ ② Σ 沿轴拉伸 (第 i 轴乘 σ_i) $\rightarrow$ ③ U 旋转 (输出)。任何线性变换 = 旋转 $\rightarrow$ 缩放 $\rightarrow$ 旋转。桥： $A^\text{T} A$ 对称半正定，谱定理对角化，特征值 = σ_i^2 、特征向量 = v_i 。

计算三步法 👉：① 求 $A^\text{T} A$ 特征值/向量，归一化作 V ， $\sigma_i = \sqrt{\lambda_i}$ 降序；② Σ 填对角；③ $u_i = \frac{1}{\sigma_i} A v_i$ (非零部分)，不足的从 $\text{Null}(A^\text{T})$ 补正交基。

👉 速算技巧：列两两正交的矩阵，奇异值=各列模长 (按降序重排 U, V 列)；单列向量 $\sigma = \|A\|$ ， $u_1 = A/\|A\|$ ， $V = [1]$ 。▲ 别漏开方、别漏除 σ ；奇异向量可整体变号。

条件数 (SVD 视角)： $\|A\|_2 = \sigma_{\max}$ ， $\|A\|_F = \sqrt{\sum \sigma_i^2}$ ， $\text{cond}_2(A) = \sigma_{\max}/\sigma_{\min}$ 。

解线性系统： A 方阵可逆 $\Rightarrow x = A^{-1} b = V\Sigma^{-1} U^\text{T} b$ ， $\Sigma_{ii}^{-1} = 1/\sigma_i$ 。

伪逆 (Moore–Penrose)： $A^+ = V\Sigma^+ U^\text{T}$ ， $\Sigma_{ii}^+ = 1/\sigma_i$ ($\sigma_i > 0$) 否则 0。满足 $AA^+ A = A$ 。